

Pill-터링

AI 알약 인식·분류

Object Detection Project | Team 3 | Kaggle mAP 0.99451 |
최종 채택 모델: YOLOv8s

26.03.16 - 26.04.02

목차

1 프로젝트 개요

- 프로젝트 목표 및 배경
- 데이터셋 구성
- 평가 지표 및 대회 형식

2 데이터 분석 결과

- 이미지 및 annotation 구조
- 클래스 불균형 문제
- 주요 해결 과제 도출

3 실험 과정

- Phase 1: Faster R-CNN 전처리
- Phase 2: Backbone 교체 실험
- Phase 3~4: YOLO 모델 도입

4 최종 결과 및 성과

- Kaggle mAP 0.99451 달성
- 최종 1등 기록
- 점진적 성능 향상 과정

5 주요 이슈 및 해결

- 주요 오류 및 디버깅
- 해결 방법 및 인사이트
- 학습-추론 일관성 확보

6 결론 및 팀 구성

- 핵심 인사이트 정리
- 팀원별 역할 및 기여
- 협업 성과

프로젝트 개요



프로젝트 목표

- 경구용 알약 이미지 인식 및 분류
- Object Detection 모델 개발
- Kaggle 대회 형식으로 진행



데이터셋 구성

- 학습 이미지: 1,489장
- 알약 카테고리: 73개
- Annotation: 4,526개
- 이미지당 평균 3개 이상 객체



주요 특징

- 하나의 이미지에 여러 알약 존재
- 클래스 간 데이터 불균형 뚜렷
- 일부 annotation 누락 문제



평가 지표

- mAP (Mean Average Precision)
- 핵심 평가 지표로 사용
- Kaggle 리더보드 기준

데이터 분석 결과



이미지 구조 분석

- 하나의 이미지당 평균 3개 이상의 알약 객체 포함
- Annotation 수가 이미지 수보다 많음
- 다중 객체 탐지 환경



Annotation 누락 문제

- 일부 이미지에서 알약 객체 존재함에도 annotation 부재
- 추가 데이터 생성 어려움
- 전처리 전략으로 보완 필요



클래스 불균형


- 최대 514개 vs 최소 7개
- 클래스별 annotation 수 편차 심각
- 데이터 불균형 완화 전략 필수



핵심 해결 과제

- 클래스 불균형 문제 해결
- Annotation 누락 대응
- 전처리 및 모델 선택 전략 수립

Phase 1: Faster R-CNN 기반 전처리 실험




Outlier Handling 및 Weighted Random Sampler

- Annotation 400개 이상 클래스를 300개로 제한
- 소수 클래스에 높은 가중치 부여
- Sampler가 가장 안정적 성능



Image Augmentation 실험

- HorizontalFlip, PhotometricDistort, RandomRotation 조합
- Conditional vs All Augmentation 비교
- 과도한 증강 시 성능 저하 확인



실험 결과 및 최적화

- Weighted Sampler 단독 적용 시 mAP 0.89 달성
- AMP 및 Gradient Accumulation 적용
- submission에 normalize 누락 수정 후 0.675에서 0.816으로 점수 증가.

Phase 2: Backbone 교체 실험 및 한계

1

Backbone 교체 실험

- ResNet50 → ResNet101, ResNet34로 교체
- 모든 경우 성능 저하 발생
- Kaggle mAP 0.117~0.359 기록

2

성능 저하 원인 분석

- 복잡한 모델의 과적합 문제
- 학습 불안정 및 OOM 에러
- 데이터 규모 대비 모델 복잡도 과다

3

소규모 데이터셋의 한계

- 1,489장의 학습 이미지는 소규모
- 경량 모델이 더 효율적
- 안정적 학습 환경 필요

4

모델 전환 결정

- 팀 전원 합의 하에 YOLO 계열로 전환
- 경량화 및 안정성 우선
- YOLOv8 및 YOLOv11 병행 실험 시작

Phase 3: YOLO 모델 도입 및 디버깅



YOLOv8/v11 병행 실험 및 초기 오류

- category_id 매핑 오류 (0-based vs 1-based)
- 데이터셋 분할 방식 오류 및 label encoding 문제 해결



YOLOv8s 첫 제출 성공

- Kaggle mAP 0.989 달성, 최종 수정을 통해 팀 최고점인 0.99451 도달
- 팀장이 직접 작성한 코드로 첫 제출 성공



증강 유무 비교 실험

- 증강 없이 학습한 경우가 더 우수한 성능
- 단순·균일한 알약 데이터 특성 반영

Phase 4: 모델 비교 및 하이퍼파라미터 튜닝



모델 비교 실험

- YOLOv8s
 - YOLOv8m
 - YOLOv11n
 - YOLOv11s
- 비교 수행



튜닝 기법

- Cosine LR
- AdamW
- Label Smoothing
- Close Mosaic
- TTA 적용 시도



실험 횟수

- 5회 이상
- 미세조정
실험 수행
- 지속적
최적화 시도



최종 성능

- YOLOv8s
- 최고 성능
- mAP
- 0.99451
달성


최종 결과 및 주요 성과

Kaggle mAP 0.99451 달성

본 프로젝트는 경구용 알약 이미지 인식 및 분류를 위한 Object Detection 모델 개발 프로젝트로, 최종적으로 YOLOv8s 모델을 채택하여 Kaggle mAP 0.99451을 달성하였음.

초기 YOLOv8s 첫 제출에서 0.989를 기록한 이후, 이미지 사이즈 조정 및 하이퍼파라미터 최적화를 통해 0.993으로 향상되었으며, 최종적으로 0.99451에 도달하였음.

특히 추론 단계에서 Normalize 전처리를 추가한 것만으로도 점수가 0.675에서 0.816으로 0.14 이상 급상승하여, 학습과 추론 단계의 전처리 일관성이 모델 성능에 결정적인 영향을 미친다는 사실을 확인함.




주요 이슈 및 해결 방법



학습 및 추론 과정에서 발생한 기술적 오류

- Kaggle 0점 반복: category_id 매핑 오류 (YOLO 0-based vs FRCNN 1-based) 수정
- 추론 점수 급락: Normalize 누락 문제 해결로 0.675→0.816 (+0.14) 향상
- CUDA OOM 에러: AMP 적용 및 batch_size 16으로 조정
- TTA 적용 위치 오류: 학습 단계가 아닌 추론 단계에만 적용



성능 최적화 과정에서 발견된 문제점

- 증강 적용 후 성능 저하: 과도한 증강이 단순·균일한 알약 데이터에서 학습 방해
- 해결: 증강 제거 후 순정 YOLOv8s 채택
- Backbone 교체 실험 실패: ResNet101/34 모두 성능 저하
- 소규모 데이터셋 특성상 경량 모델이 더 효과적임을 확인

결론 및 인사이트

1

모델 선택 및 데이터 처리 전략

- 소규모 데이터셋: 경량 모델 (YOLOv8s)이 복잡한 모델보다 효율적
- 데이터 불균형: Weighted Random Sampler가 가장 효과적
- 증강 전략: 과도한 증강은 단순 데이터에서 성능 저하 유발

2

팀 협업의 중요성

- 매일 스크럼 회의 및 협업 노트 활용
- 역할 분담 및 지속적 소통
- 팀 전체 실험 효율 향상에 기여

프로젝트를 통해 얻은 핵심 학습 내용

- A) 1,489장의 학습 이미지와 73개 알약 카테고리로 구성된 소규모 데이터셋에서 mAP 0.99451를 달성함.
- B) 실험 과정에서 복잡한 모델보다 경량 모델이 더 안정적이며, Weighted Random Sampler가 데이터 불균형 완화에 가장 효과적임을 확인함.
- C) 학습과 추론 단계의 전처리 일관성이 성능에 결정적 영향을 미친다는 사실을 실증함.
- D) 팀원 5명이 각자의 역할을 성실히 수행하고 매일 회의와 디스코드를 통해 지속적으로 소통한 결과, 효율적인 실험 진행과 빠른 문제 해결이 가능하였음.

팀 구성 및 역할

유연정

- PM
- 데이터 전처리
- 모델 설계 및 실험

김현숙

- 데이터 전처리
- 모델 설계 및 실험

이현진

- 모델 설계 및 실험
- PPT 제작

송우현

- 모델 설계 및 실험

은광성

- 데이터 전처리
- 모델 실험